

RANDOM VARIABLES

Types

- Discrete:** valeurs entieres nombre lancers
- Continuous:** valeurs decimales temps poids

Expected Value Esperance

E X egal mu egal Somme xi fois P X egal xi
Moyenne ponderee des valeurs possibles

Variance et Standard Deviation

Var X egal sigma carre egal Somme xi moins E X carre fois P X egal xi
SD X egal sigma egal racine Var X

Linear Combinations

Expected Value:
E aX plus bY egal a fois E X plus b fois E Y
Variance si independants:
Var aX plus bY egal a carre fois Var X plus b carre fois Var Y
SD aX plus bY egal racine Var aX plus bY

Important Distinctions

E X plus X egal E 2X egal 2 E X correct
Var X plus X egal 2 Var X different Var 2X egal 4 Var X
X plus X different 2X pour variance

Fair Game Jeu Equitable

Cout egal Gain espere donc E profit egal 0
Exemple: cout 5 dollars gain espere 5 dollars

PYTHON PANDAS ESSENTIALS

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('file.csv')

df.head() 5 premieres lignes
df.tail() 5 dernieres
df.info() types missing values
df.describe() stats mean std min max
quartiles
df.shape rows cols
df.columns noms colonnes
df.sample(10) 10 lignes aleatoires

df['col'] 1 colonne
df[['col1','col2']] plusieurs
df.iloc[0:5] lignes par index
df.loc[df['col'] plus grand 10] filtre

df['col'].mean() moyenne
df['col'].median() mediane
df['col'].std() ecart-type
df['col'].var() variance
df['col'].min() minimum
df['col'].max() maximum
df['col'].quantile([.25,.5,.75]) quartiles
df['col'].corr(df['col2']) correlation

df.isnull().sum() compte NaN par col
df.dropna() supprimer lignes avec NaN
df.fillna(value) remplir NaN

df.groupby('cat')['num'].mean()
df.groupby(['c1','c2'])['num'].sum()
```

PYTHON VISUALISATIONS

```
df['col'].hist(bins=10)
plt.xlabel('Label')
plt.ylabel('Frequency')
plt.title('Title')
plt.show()

sns.boxplot(x='cat', y='num', data=df)
plt.show()

plt.scatter(df['x'], df['y'])
```

```
plt.xlabel('X'); plt.ylabel('Y')
plt.show()

corr = df[['c1','c2','c3']].corr()
sns.heatmap(corr, annot=True,
cmap='coolwarm')
plt.show()

df['cat'].value_counts().plot(kind='bar')
plt.show()
```

PYTHON SCIKIT-LEARN IRIS

```
from sklearn import datasets
import pandas as pd

iris = datasets.load_iris()
iris.data matrice donnees 150x4
iris.target labels 0 1 2
iris.feature_names noms features
iris.target_names noms classes

df = pd.DataFrame(data=iris.data
columns=iris.feature_names)

iris.data.mean(0) mean par feature
iris.data.std(0) std par feature
iris.data.min(0) min par feature
iris.data.max(0) max par feature

species = [iris.target_names[i]
for i in iris.target]
df['species'] = species
```

FORMULES CLES RESUMEES

Concept	Formule EN	FR
Mean	x barre egal Somme xi divise n	Moyenne
Median	50th percentile	Mediane
Variance	s carre egal Somme xi moins x barre carre divise n moins 1	Variance
Std Dev	s egal racine s carre	Ecart-type
IQR	Q3 moins Q1	Ecart interquartile
Outlier	inferieur Q1 moins 1.5 IQR ou superieur Q3 plus 1.5 IQR	Valeur aberrante
P A union B	P A plus P B moins P A inter B	Union
P A inter B	P A sachant B fois P B	Intersection
P A sachant B	P A inter B divise P B	Conditionnel
Bayes	P A sachant B egal P B sachant A fois P A divise P B	Theoreme Bayes
Independence	P A inter B egal P A fois P B	Independance
E X	Somme xi fois P xi	Esperance
Var X	Somme xi moins mu carre fois P xi	Variance VA

EXERCICES TYPES

Type 1: Statistiques Descriptives

Donnees: 57 66 69 71 72 73 74 77 78 78
79 79 81 81 82 83 83 88 89 94
1 Trier donnees
2 Mean egal Somme xi divise n egal 1554
divise 20 egal 77.7
3 Median egal x10 plus x11 divise 2 egal
78 plus 79 divise 2 egal 78.5
4 Q1 egal x5 plus x6 divise 2 egal 72
plus 73 divise 2 egal 72.5
5 Q3 egal x15 plus x16 divise 2 egal 82
plus 83 divise 2 egal 82.5
6 IQR egal 82.5 moins 72.5 egal 10
7 Lower W egal max min Q1 moins 1.5 IQR
egal max 57 57.5 egal 57.5
8 Upper W egal min max Q3 plus 1.5 IQR
egal min 94 97.5 egal 94
9 Outliers: aucun tous dans whiskers

Type 2: Probabilite Conditionnelle

Tableau: 1000 etudiants 60 pourcent
croient rechauffement
Democrats liberaux: 20 pourcent dont 18
pourcent croient
P croit sachant Dem-lib egal question
egal P croit inter Dem-lib divise P Dem-
lib
egal 0.18 divise 0.20 egal 0.90 egal 90
pourcent

Type 3: Bayes avec Tree Diagram

Cancer 1.7 pourcent Mammo: 78 pourcent
si cancer 10 pourcent faux positif
P cancer sachant plus egal question
P C inter plus egal 0.017 fois 0.78 egal
0.0133
P NC inter plus egal 0.983 fois 0.10
egal 0.0983
P C sachant plus egal 0.0133 divise
0.0133 plus 0.0983 egal 0.12 egal 12
pourcent

Type 4: Expected Value

Jeu: 3 des si identiques gagne N pts
sinon moins 1
P 3 identiques egal 6 divise 216 egal 1
divise 36
P pas identiques egal 35 divise 36
Fair game: E X egal 0
1 divise 36 fois N plus 35 divise 36
fois moins 1 egal 0
N divise 36 egal 35 divise 36 donc N
egal 35

Type 5: Au Moins Un

MCQ: 5 questions 4 choix deviner
P correct egal 1 divise 4 P faux egal 3
divise 4
P superieur egal 1 correct egal 1 moins
P tous faux
egal 1 moins 3 divise 4 puissance 5 egal
1 moins 243 divise 1024 egal 781 divise
1024 environ 76 pourcent

RAPPELS IMPORTANTS

Mean sensible aux outliers Median robuste
Right-skewed: mean superieur median
Left-skewed: mean inferieur median
IQR egal Q3 moins Q1 50 pourcent milieu
Outliers si inferieur Q1 moins 1.5 IQR ou superieur
Q3 plus 1.5 IQR
Correlation different Causation
P A union B different P A plus P B si non-disjoint
Independence: P A sachant B egal P A
Au moins 1: utiliser complement
Var X plus X egal 2 Var X different Var 2X egal 4 Var X
Histogram: check for skew outliers modality
Boxplot: median quartiles outliers visibles

VOCABULAIRE FR EN

Moyenne	Mean	Ecart-type	Std Deviation
Mediane	Median	Variance	Variance
Quartile	Quartile	Etendue	Range
Asymetrique	Skewed	Symetrique	Symmetric
Queue	Tail	Aberrant	Outlier
Echantillon	Sample	Population	Population
Variable	Variable	Observation	Observation
Categorique	Categorical	Numerique	Numerical

Conseils Exam

Lire attentivement questions conditional vs joint
Dessiner tree diagrams pour Bayes
Verifier si evenements independants ou disjoint
Utiliser complement pour au moins
Attention unites et arrondis demandes

DATA ANALYTICS - FEUILLE DE REVISION COMPLETE

CH1: INTRODUCTION TO DATA

Types de Variables

Numerical/Quantitative: nombres age height
Continuous: decimales possibles temps 3.5h
Discrete: entiers nombre enfants 2
Categorical/Qualitative: categories
Ordinal: ordre logique petit moyen grand
Nominal: pas ordre couleur rouge bleu

Relationships

Associated: variables liees tabac cancer
Independent: pas de lien
Association ne implique pas Causation

Sampling

Simple Random: chaque individu meme proba
Stratified: diviser en strates puis echantillon
Cluster: diviser en clusters puis selectionner clusters entiers
Multistage: combinaison methodes

Sampling Bias

Selection bias: methode favorise certains
Non-response bias: certains ne repondent pas
Undercoverage: certains groupes exclus
Response bias: reponses influencees

CH2: SUMMARIZING DATA

Visualisations

Scatterplot: relation 2 var numeriques
Histogram: distribution 1 var numerique
Box plot: Q1 mediane Q3 whiskers outliers
Dot plot: chaque point observation
Bar plot: var categoriques hauteur frequence
Mosaic plot: 2 var categoriques

Distribution Shape

Modality: unimodal 1 pic bimodal 2 pics uniform
Skewness:
Right-skewed: queue droite mean plus grand median
Left-skewed: queue gauche mean plus petit median
Symmetric: mean environ median

Mesures de Centre

Mean Moyenne: $\bar{x}$ barre egal Somme $\sum x_i$ divise n
Median Mediane: valeur milieu 50th

percentile
 n impair: valeur centrale
 n pair: moyenne des 2 valeurs centrales

Mesures de Dispersion

Variance: s^2 carre egal Somme $\sum (x_i - \bar{x})^2$ divise $n - 1$
Standard Deviation SD: s egal racine s^2
IQR: $Q_3 - Q_1$
Range: max moins min

Percentiles et Quartiles

Q1 25th percentile: 25 pourcent donnees en dessous
Q2 50th egal Median: 50 pourcent en dessous
Q3 75th: 75 pourcent en dessous
IQR egal Q3 moins Q1: etalement 50 pourcent central

Box Plot Components

Lower Whisker: max min Q_1 moins 1.5 fois IQR
Upper Whisker: min max Q_3 plus 1.5 fois IQR
Outliers: valeurs au dela des whiskers

Robust Statistics

Robust resistantes aux outliers: Median IQR
Non-robust: Mean SD Range
Utiliser median IQR si skewed ou outliers
Utiliser mean SD si symmetric

CH3: PROBABILITY

Regles de Base

Probability: $0 \leq P(A) \leq 1$
Complement: $P(A^c) = 1 - P(A)$
Sample Space: Somme $P(\text{outcomes}) = 1$

Law of Large Numbers

Plus observations proportion converge vers proba reelle
Gamblers Fallacy: piece pas due pour pile apres 10 faces
Chaque evenement independant a meme probabilite

Disjoint Events Mutuellement Exclusifs

Definition: $A \cap B = \emptyset$
 $P(A \cap B) = 0$

Ne peuvent arriver en meme temps
Addition Rule: $P(A \cup B) = P(A) + P(B)$ si disjoint

Non-Disjoint Events

General Addition Rule:
 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Independence

Definition: A et B independants si:
 $P(A \cap B) = P(A)P(B)$
Product Rule: $P(A \cap B) = P(A)P(B)$
Pour k evenements: $P(A_1 \cap \dots \cap A_k) = P(A_1)P(A_2) \dots P(A_k)$

Conditional Probability

$P(A|B) = \frac{P(A \cap B)}{P(B)}$
B si $P(B) > 0$
Probabilite de A sachant que B est arrive

General Multiplication Rule

$P(A \cap B) = P(A)P(B|A) = P(B)P(A|B)$

Bayes Theorem

$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{P(B)}$
Avec partition $A_1, \dots, A_k$:
 $P(A_i|B) = \frac{P(A_i)P(B|A_i)}{P(A_1)P(B|A_1) + \dots + P(A_k)P(B|A_k)}$

Tree Diagrams

Branches probabilites conditionnelles
Multiplier le long des branches pour $P(A \cap B)$
Utile pour inverser probabilites Bayes

At Least One Au Moins Un

P au moins 1 egal 1 moins P aucun
Exemple: P superieur egal 1 face sur 3 lancers egal 1 moins un demi cube egal 7 sur 8

Sampling

With Replacement: tirages independants
Without Replacement: tirages dependants
Peu impact si population tres grande