

Introduction to Data Analysis

Final exam, 4 January 2024. Time allowed: 2 hours.

English version

Q1

Suppose a survey of 800 employees in a large corporation over a 5-year period was conducted. The following results were obtained regarding their department and the number of promotions they received:

Department / Promotions	0-1 Promotions	2-3 Promotions	4+ Promotions
Marketing	100	50	10
HR	120	60	20
IT	80	100	60
Finance	150	40	10

Suppose we randomly select an employee from the corporation.

- What is the probability that the employee is in the IT department, given they have received 2-3 promotions?
- What is the probability that the employee received 0-1 promotions, given they are in the Marketing department?
- What is the probability that the employee received 4+ promotions, given they are in either the HR or Finance departments?
- What is the probability that the employee is in the Finance department?

[2 marks]

Q2

A mid-sized software company has evaluated its employees and found that 60% are rated as high performers (H) and 40% as average performers (A). Further analysis shows that 70% of the high performers have completed advanced training (T), whereas only 20% of the average performers have not completed advanced training (T'). If an employee is an average performer, what is the probability that they have completed advanced training?

[2 marks]

Q3

When the Final exam statistic test scores of 200 students were analyzed, a mean score of 82 was obtained with a standard deviation of 3. Assuming that the scores were normally distributed, how many students had scores between 78 and 95? Justify your answer.

[2 marks]

Q4

We would like to design a fair game. The game consists of tossing three coins; if you get three Tails or three Heads, you win N dollars; otherwise, you lose one dollar. 1) Find the value of N which will make the game fair. 2) Using the results of 1), calculate the standard deviation of the winning/loss.

[3 marks]

Q5

A group of friends debated whether more men use smartphones than women. They consulted a research study of smartphone use among adults. The results of the survey indicate that of the 973 men randomly sampled, 379 use smartphones. For women, 404 of the 1304 who were randomly sampled use smartphones.

- Is there evidence that the proportion of men who use smartphones is higher than that of women who use smartphones? Formulate the appropriate hypotheses and test at the 5% level of significance.
- Determine the 95% confidence interval for the difference between the two proportions.

iii. [4 marks]

Q6

The National Center for Health Statistics (NCHS) provided data on the distribution of weight (in categories) among Americans in 2002. The distribution was based on specific values of body mass index (BMI) computed as weight in kilograms over height in meters squared. Americans in 2002 were distributed as follows: 2% Underweight (BMI < 18.5), 39% Normal Weight (BMI 18.5-24.9), 36% Overweight (BMI 25.0-29.9), and 23% Obese (BMI > 30). In 2006, the BMI of a random sample of $n = 3326$ participants was computed and the results are shown in the table below:

	Underweight BMI < 18.5	Normal Weight BMI 18.5-24.9	Overweight BMI 25.0-29.9	Obese BMI > 30
Number of participants	20	932	1374	1000

Is there any evidence that the distributions of BMI in 2002 and 2006 are different? Use a 5% level of significance.

[3 marks]

Q7

A public opinion poll surveyed a simple random sample of 1000 voters. Respondents were classified by gender (male or female) and by voting preference (Republican, Democrat, or Independent). Results are shown in the contingency table below.

	Voting Preferences			Row total
	Rep	Dem	Ind	
Male	200	150	50	400
Female	250	300	50	600
Column total	450	450	100	1000

Do the men's voting preferences differ significantly from the women's preferences? Use a 0.05 level of significance.

[4 marks]

French Version

Q1

Supposons qu'une enquête sur 800 employés d'une grande entreprise a été menée sur une période de 5 ans. Les résultats suivants ont été obtenus concernant leur département et le nombre de promotions qu'ils ont reçues :

Department / Promotions	0-1 Promotions	2-3 Promotions	4+ Promotions
Marketing	100	50	10
HR	120	60	20
IT	80	100	60
Finance	150	40	10

Supposons que nous sélectionnons aléatoirement un employé de l'entreprise.

- Quelle est la probabilité que l'employé soit du département IT, sachant qu'il a reçu 2-3 promotions ?
- Quelle est la probabilité que l'employé ait reçu 0-1 promotions, sachant qu'il est du département Marketing ?
- Quelle est la probabilité que l'employé ait reçu 4+ promotions, sachant qu'il est des départements RH ou Finance ?
- Quelle est la probabilité que l'employé soit du département Finance ?

[2 marks]

Q2

Une entreprise de logiciels de taille moyenne a évalué ses employés et a constaté que 60 % d'entre eux sont classés comme performants (H) et 40 % comme performants moyens (A). Une analyse plus approfondie révèle que 70 % des employés performants ont suivi une formation avancée (T), tandis que seulement 20 % des performants moyens n'ont pas suivi de formation avancée (T'). Si un employé est un performant moyen, quelle est la probabilité qu'il ait suivi une formation avancée ?

[2 marks]

Q3

Lors de l'analyse des résultats de l'examen final de statistiques de 200 étudiants, il a été constaté que le score moyen était de 82 avec un écart-type de 3. En supposant que les scores suivent une distribution normale, combien d'étudiants ont obtenu des scores compris entre 78 et 95 ? Justifiez votre réponse.

[2 marks]

Q4

Nous souhaitons concevoir un jeu équitable. Le jeu consiste à lancer trois pièces de monnaie ; si vous obtenez trois piles ou trois faces, vous gagnez N dollars ; sinon, vous perdez un dollar. 1) Déterminez la valeur de N qui rendra le jeu équitable. 2) En utilisant les résultats du point 1), calculez l'écart-type des gains et des pertes.

[3 marks]

Q5

Un débat a émergé parmi un groupe d'amis concernant l'usage des smartphones par les hommes comparés à celui des femmes. Pour trancher, ils se sont référés à une étude sur l'utilisation des smartphones par les adultes. Selon cette étude, parmi 973 hommes échantillonnés aléatoirement, 379 utilisent des smartphones, tandis que parmi 1304 femmes échantillonnées, 404 en utilisent.

i. Existe-t-il des preuves statistiques indiquant que la proportion d'hommes utilisant des smartphones est supérieure à celle des femmes ? Élaborez et testez les hypothèses appropriées avec un seuil de signification de 5%.

ii. Calculez l'intervalle de confiance à 95% pour mesurer l'écart entre les proportions des deux groupes.

[4 marks]

Q6

Le Centre national de statistiques de santé (NCHS) a fourni des données sur la répartition du poids (catégorisé) parmi les Américains en 2002, basées sur l'indice de masse corporelle (BMI) calculé comme le poids en kilogrammes divisé par la taille en mètres carrés. En 2002, la répartition était la suivante : 2 % en insuffisance pondérale (BMI < 18.5), 39 % de poids normal (BMI 18.5-24.9), 36 % en surpoids (BMI 25.0-29.9) et 23 % obèses (BMI > 30). En 2006, l' BMI d'un échantillon aléatoire de 3326 participants a été calculé, et les résultats sont présentés dans le tableau ci-dessous :

	Underweight BMI<18.5	Normal Weight BMI 18.5-24.9	Overweight BMI 25.0-29.9	Obese BMI > 30
Number of participants	20	932	1374	1000

Existe-t-il des preuves d'une différence dans la répartition de l' BMI entre 2002 et 2006 ? Réalisez un test avec un niveau de signification de 5 %.

[3 marks]

Q7

Dans le cadre d'un sondage d'opinion publique, un échantillon aléatoire simple de 1000 électeurs a été interrogé. Les participants ont été classés par genre (homme ou femme) et par préférence de vote (Républicain, Démocrate ou Indépendant). Les résultats sont présentés dans le tableau de contingence ci-dessous.

	Voting Preferences			Row total
	Rep	Dem	Ind	
Male	200	150	50	400
Female	250	300	50	600
Column total	450	450	100	1000


Y a-t-il une différence significative entre les préférences de vote des males et celles des females ? Analysez cela avec un seuil de signification de 5 %.

[4 marks]

Good Luck, Good Luck

APPENDIX: PROBABILITY TABLES


NORMAL PROBABILITY TABLE




Z	Second decimal place of Z									
	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

*For $Z \geq 3.50$, the probability is greater than or equal to 0.9998.

T-PROBABILITY TABLE



CHI-SQABRE PROBABILITY TABLE



Inference for categorical data

Case	Conditions for Hypothesis Testing	Point estimate (PE)	Hypothesis Testing	Conditions for CI	Confidence Intervals
Single proportion of size n, p: observed proportion p ₀ : expected proportion	. Independence . At least 10 successes and failures n*p ₀ ≥ 10 n*(1- p ₀) ≥ 10	$\hat{p} = p$	- H ₀ : p=p ₀ 1. Check conditions 2. $SE = \sqrt{\frac{p_0*(1-p_0)}{n}}$ 3. $Z = \frac{p-p_0}{SE}$ 4. Calculate p-value 5. if p-value is low, reject H ₀	. Independence . At least 10 successes and failures n*p ≥ 10 n*(1- p) ≥ 10	1. Check conditions 2. $SE = \sqrt{\frac{p*(1-p)}{n}}$ 3. $ME = z^* * SE$ 4. $CI = p \pm ME$ z*=1.96 for 95% confidence interval
Difference of two proportions p ₁ with sample size n ₁ , p ₂ with sample size n ₂	. Independence within groups . Independence between groups . At least 10 successes and failures in the two groups	$\hat{p}_1 - \hat{p}_2 = p_1 - p_2$	H ₀ : p ₁ =p ₂ 1. Calculate Pooled estimate of a proportion $\hat{p} = \frac{\#success1 + \#success2}{n_1 + n_2}$ 2. $SE = \sqrt{\frac{\hat{p}*(1-\hat{p})}{n_1} + \frac{\hat{p}*(1-\hat{p})}{n_2}}$ 3. $Z = \frac{p_1 - p_2}{SE}$ 4. Calculate p-value 5. If p-value is low, reject H ₀	. Independence between groups . At least 10 successes and failures in the two groups	1. Check conditions 2. $SE = \sqrt{\frac{p_1*(1-p_1)}{n_1} + \frac{p_2*(1-p_2)}{n_2}}$ 3. $ME = z^* * SE$ 4. $CI = p \pm ME$
Goodness of fit	. Independence: Each case that contributes a count to the table must be independent of all the other cases in the table. . Sample size: Each particular scenario (i.e. cell) must have at least 5 expected cases. . df > 1: Degrees of freedom must be greater than 1.		1. H ₀ : The observed counts follow the same distribution as the expected counts 2. Calculate the chi-square statistic $\sum_{i=1}^n \frac{(O - E)^2}{E}$ 3. Calculate the degree of freedom df=n-1 4. Calculate p-value using chi-square probability table (tail area under the chi-square distribution) 5. if p-value is low, reject H ₀		