

COMPTE RENDU

Analyse de données - TP9 Fondements de l'Inférence - Partie 1
3e année Cybersécurité - École Supérieure d'Informatique et du
Numérique (ESIN)
Collège d'Ingénierie & d'Architecture (CIA)

Étudiant : HATHOUTI Mohammed Taha
Filière : Cybersecurité
Année : 2025/2026
Enseignants : M.MOUKAFIH
Date : 27 novembre 2025

Table des matières

1	Exercice 1 : QCM	2
1.1	Question 1	2
1.2	Question 2	2
1.3	Question 3	2
1.4	Question 4	2
1.5	Question 5	3
1.6	Question 6	3
1.7	Question 7	3
1.8	Question 8	3
1.9	Question 9	4
2	Exercice 2 : Estimations et intervalles de confiance	4
2.1	Question 1	4
2.2	Question 2	4
2.3	Question 3	5
2.4	Question 4	6
2.5	Question 5	6
2.6	Question 6	7
2.7	Question 7	8
2.8	Question 8	8

1 Exercice 1 : QCM

1.1 Question 1

Laquelle des conditions suivantes n'est pas requise pour que le Théorème Central Limite s'applique aux proportions d'échantillon ?

- a. L'échantillon doit être sélectionné de manière aléatoire.
- b. **La population doit suivre une distribution normale.**
- c. La taille de l'échantillon doit être inférieure à 10% de la population.
- d. Le nombre attendu de succès et d'échecs doit être d'au moins 10 chacun.

1.2 Question 2

L'erreur standard d'une proportion d'échantillon $\hat{p}$ est donnée par :

- a. $SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$
- b. $SE = \frac{\hat{p}(1-\hat{p})}{n}$
- c. $SE = \sqrt{n\hat{p}(1-\hat{p})}$
- d. $SE = \frac{\hat{p}}{\sqrt{n}}$

1.3 Question 3

Augmenter la taille de l'échantillon tout en gardant le niveau de confiance constant va :

- a. Augmenter la marge d'erreur.
- b. **Diminuer la marge d'erreur.**
- c. N'avoir aucun effet sur la marge d'erreur.
- d. Augmenter la variabilité de la proportion d'échantillon.

Explication : La marge d'erreur $= z^* \times SE = z^* \times \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$. Quand n augmente, SE diminue, donc la marge d'erreur diminue.

1.4 Question 4

Laquelle des affirmations suivantes décrit le mieux un intervalle de confiance à 95% ?

- a. Il y a une probabilité de 95% que le paramètre de population se trouve dans l'intervalle.
- b. 95% du temps, la proportion d'échantillon se trouvera dans l'intervalle.
- c. **Dans 95% de tous les échantillons possibles, l'intervalle de confiance calculé à partir de ces échantillons contiendra le vrai paramètre de population.**
- d. L'intervalle contient 95% des données de la population.

Explication : Si on répétait l'échantillonnage de nombreuses fois, 95% des intervalles construits contiendraient le vrai paramètre.

1.5 Question 5

Si le niveau de confiance est augmenté de 90% à 95%, qu'arrive-t-il à la largeur de l'intervalle de confiance, en supposant que la taille de l'échantillon reste la même ?

- a. Il devient plus étroit.
- b. **Il devient plus large.**
- c. Il reste le même.
- d. Il pourrait devenir plus large ou plus étroit, selon les données.

Explication : Pour avoir plus de confiance (95% vs 90%), on doit élargir l'intervalle. Le z^* pour 95% (1.96) est plus grand que celui pour 90% (1.645).

1.6 Question 6

Le Théorème Central Limite stipule qu'à mesure que la taille de l'échantillon augmente :

- a. La distribution des données d'échantillon devient plus asymétrique.
- b. **La distribution d'échantillonnage de la moyenne d'échantillon se rapproche d'une distribution normale.**
- c. La moyenne d'échantillon devient égale à la moyenne de population.
- d. La variabilité dans la population diminue.

1.7 Question 7

Laquelle des affirmations suivantes est vraie concernant l'erreur standard ?

- a. Elle mesure la variabilité des données de population.
- b. **Elle diminue à mesure que la taille de l'échantillon augmente.**
- c. Elle n'est pas affectée par la taille de l'échantillon.
- d. Elle est la même que l'écart-type de population.

Explication : $SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$: quand n augmente, ES diminue car il est au dénominateur.

1.8 Question 8

Dans la construction d'un intervalle de confiance pour une proportion de population, la valeur critique z^* dépend :

- a. De la taille de l'échantillon.
- b. **Du niveau de confiance désiré.**
- c. De la proportion d'échantillon.
- d. De la taille de la population.

1.9 Question 9

La marge d'erreur dans un intervalle de confiance tient compte de :

- Les erreurs dues aux méthodes d'échantillonnage biaisées.
- Les erreurs dues à la variabilité d'un échantillon à l'autre.**
- Les erreurs dues aux fautes de saisie de données.
- Les erreurs dues à la non-réponse dans les sondages.

2 Exercice 2 : Estimations et intervalles de confiance

2.1 Question 1

Une enquête a été menée pour estimer la proportion d'étudiants universitaires qui préfèrent les cours en ligne aux cours en présentiel. Sur un échantillon aléatoire de 500 étudiants, 290 ont indiqué une préférence pour les cours en ligne. Calculez la proportion d'échantillon et interprétez-la dans le contexte de l'étude.

Données :

- $n = 500$ (taille de l'échantillon)
- $x = 290$ (nombre d'étudiants préférant les cours en ligne)

Calcul de la proportion d'échantillon :

$$\hat{p} = \frac{x}{n} = \frac{290}{500} = 0.58$$

Résultat final

$$\hat{p} = 0.58 = 58\%$$

Interprétation : Dans cet échantillon de 500 étudiants universitaires, 58% préfèrent les cours en ligne aux cours en présentiel. Cette proportion d'échantillon ($\hat{p} = 0.58$) est notre meilleure estimation ponctuelle de la vraie proportion de tous les étudiants universitaires qui préfèrent les cours en ligne.

2.2 Question 2

Sur la base de l'enquête de la Question 1, calculez l'erreur standard de la proportion d'échantillon.

Formule de l'erreur standard :

$$SE = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Données :

- $\hat{p} = 0.58$
- $n = 500$

Calcul :

$$\begin{aligned}SE &= \sqrt{\frac{0.58 \times (1 - 0.58)}{500}} = \sqrt{\frac{0.58 \times 0.42}{500}} \\SE &= \sqrt{\frac{0.2436}{500}} = \sqrt{0.0004872} \\SE &\approx 0.0221\end{aligned}$$

Résultat final

$$SE \approx 0.0221 = 2.21\%$$

L'erreur standard de la proportion d'échantillon est d'environ 2.21%. Cela représente la variabilité typique de l'estimation de la proportion d'un échantillon à l'autre.

2.3 Question 3

Vérifiez si les conditions du Théorème Central Limite (TCL) sont satisfaites pour la proportion d'échantillon de la Question 1.

Les conditions du TCL pour les proportions :

1. **Indépendance :** L'échantillon doit être aléatoire et la taille de l'échantillon doit être $< 10\%$ de la population.
2. **Succès-Échec :** $n\hat{p} \geq 10$ et $n(1 - \hat{p}) \geq 10$

Vérification :

Condition 1 - Indépendance :

- L'énoncé indique que c'est un échantillon **aléatoire**
- $n = 500 < 10\%$ de tous les étudiants universitaires

Condition 2 - Succès-Échec :

$$n\hat{p} = 500 \times 0.58 = 290 \geq 10 \quad \checkmark$$

$$n(1 - \hat{p}) = 500 \times 0.42 = 210 \geq 10 \quad \checkmark$$

Résultat final

Toutes les conditions du TCL sont satisfaites.

- Échantillon aléatoire : OUI
- $n < 10\%$ de la population : OUI
- Nombre de succès = $290 \geq 10$: OUI
- Nombre d'échecs = $210 \geq 10$: OUI

On peut donc utiliser l'approximation normale pour construire un intervalle de confiance.

2.4 Question 4

Construisez un intervalle de confiance à 95% pour la vraie proportion d'étudiants universitaires qui préfèrent les cours en ligne. Interprétez cet intervalle dans son contexte.

Formule de l'intervalle de confiance :

$$IC = \hat{p} \pm z^* \times SE$$

Données :

- $\hat{p} = 0.58$
- $SE = 0.0221$ (calculé à la Question 2)
- Pour 95% de confiance : $z^* = 1.96$

Calcul de la marge d'erreur :

$$ME = z^* \times SE = 1.96 \times 0.0221 = 0.0433$$

Calcul des bornes :

$$\text{Borne inférieure} = 0.58 - 0.0433 = 0.5367$$

$$\text{Borne supérieure} = 0.58 + 0.0433 = 0.6233$$

Résultat final

$$IC_{95\%} = [0.537, 0.623]$$

ou

$$IC_{95\%} = [53.7\%, 62.3\%]$$

Interprétation : Nous sommes confiants à 95% que la vraie proportion de tous les étudiants universitaires qui préfèrent les cours en ligne se situe entre 53.7% et 62.3%.

Cela signifie que si nous répétions cette enquête de nombreuses fois avec différents échantillons de 500 étudiants, environ 95% des intervalles construits contiendraient la vraie proportion de la population.

2.5 Question 5

Supposons que les chercheurs voulaient une marge d'erreur d'au plus 3% à un niveau de confiance de 95%. Quelle est la taille minimale d'échantillon requise pour atteindre cet objectif ?

Formule de la taille d'échantillon :

$$n = \left(\frac{z^*}{ME} \right)^2 \times \hat{p}(1 - \hat{p})$$

Données :

- $ME = 0.03$ (3%)
- $z^* = 1.96$ (pour 95%)

— $\hat{p} = 0.58$ (estimation de la Question 1)

Calcul :

$$n = \left(\frac{1.96}{0.03} \right)^2 \times 0.58 \times 0.42$$

$$n = (65.333)^2 \times 0.2436$$

$$n = 4268.44 \times 0.2436 = 1039.79$$

On arrondit TOUJOURS vers le haut pour garantir la marge d'erreur souhaitée.

Résultat final

$$n = 1040 \text{ étudiants}$$

Pour obtenir une marge d'erreur d'au plus 3% avec un niveau de confiance de 95%, les chercheurs doivent interroger au minimum **1040 étudiants**.

2.6 Question 6

Un organisme de sondage rapporte que 52% d'un échantillon de 1 200 électeurs inscrits soutiennent un candidat particulier. Calculez un intervalle de confiance à 99% pour la vraie proportion d'électeurs qui soutiennent le candidat.

Données :

— $\hat{p} = 0.52$

— $n = 1200$

— Pour 99% de confiance : $z^* = 2.576$

Calcul de l'erreur standard :

$$SE = \sqrt{\frac{0.52 \times 0.48}{1200}} = \sqrt{\frac{0.2496}{1200}} = \sqrt{0.000208}$$

$$SE \approx 0.0144$$

Calcul de la marge d'erreur :

$$ME = 2.576 \times 0.0144 = 0.0371$$

Calcul de l'intervalle :

$$IC_{99\%} = 0.52 \pm 0.0371 = [0.4829, 0.5571]$$

Résultat final

$$IC_{99\%} = [0.483, 0.557]$$

ou

$$IC_{99\%} = [48.3\%, 55.7\%]$$

Nous sommes confiants à 99% que la vraie proportion d'électeurs qui soutiennent ce candidat se situe entre 48.3% et 55.7%.

2.7 Question 7

Expliquez comment l'augmentation du niveau de confiance de 95% à 99% affecte la largeur d'un intervalle de confiance, en gardant la taille de l'échantillon constante.

Analyse théorique :

La largeur de l'intervalle de confiance dépend de la marge d'erreur :

$$\text{Largeur} = 2 \times \text{ME} = 2 \times z^* \times \text{SE}$$

Quand le niveau de confiance augmente :

- Le z^* augmente :
 - 95% $\rightarrow z^* = 1.96$
 - 99% $\rightarrow z^* = 2.576$
- L'SE reste constant (car n ne change pas)
- Donc la ME augmente
- Donc la largeur augmente

Exemple numérique :

Considérons $\hat{p} = 0.52$ et $n = 1200$ (données de la Question 6) :

$$\text{SE} = 0.0144$$

Pour 95% :

$$\text{ME}_{95\%} = 1.96 \times 0.0144 = 0.0282$$

$$\text{Largeur}_{95\%} = 2 \times 0.0282 = 0.0564 = 5.64\%$$

Pour 99% :

$$\text{ME}_{99\%} = 2.576 \times 0.0144 = 0.0371$$

$$\text{Largeur}_{99\%} = 2 \times 0.0371 = 0.0742 = 7.42\%$$

Résultat final

L'intervalle devient PLUS LARGE.

Quand on augmente le niveau de confiance de 95% à 99% :

- La largeur passe de 5.64% à 7.42%
- Augmentation de $\frac{7.42-5.64}{5.64} \approx 31.6\%$

Interprétation : Pour être plus confiant (99% vs 95%), on doit accepter un intervalle plus large. C'est un compromis : plus de confiance = moins de précision.

2.8 Question 8

Dans un processus de contrôle qualité, une usine teste 150 articles et constate que 9 sont défectueux. Construisez un intervalle de confiance à 90% pour la vraie proportion d'articles défectueux produits par l'usine.

Données :

- $n = 150$

- $x = 9$ (articles défectueux)
- Niveau de confiance = 90% $\rightarrow z^* = 1.645$

Calcul de la proportion d'échantillon :

$$\hat{p} = \frac{9}{150} = 0.06$$

Vérification des conditions du TCL :

$$n\hat{p} = 150 \times 0.06 = 9 < 10 \text{ (limite!)}$$

$$n(1 - \hat{p}) = 150 \times 0.94 = 141 \geq 10 \checkmark$$

Note : La condition $n\hat{p} \geq 10$ n'est pas tout à fait satisfaite (9 vs 10), mais on peut procéder avec prudence.

Calcul de l'erreur standard :

$$SE = \sqrt{\frac{0.06 \times 0.94}{150}} = \sqrt{\frac{0.0564}{150}} = \sqrt{0.000376}$$

$$SE \approx 0.0194$$

Calcul de la marge d'erreur :

$$ME = 1.645 \times 0.0194 = 0.0319$$

Calcul de l'intervalle :

$$IC_{90\%} = 0.06 \pm 0.0319 = [0.0281, 0.0919]$$

Résultat final

$$IC_{90\%} = [0.028, 0.092]$$

ou

$$IC_{90\%} = [2.8\%, 9.2\%]$$

Nous sommes confiants à 90% que la vraie proportion d'articles défectueux produits par l'usine se situe entre 2.8% et 9.2%.

Note : La condition $n\hat{p} \geq 10$ n'est pas parfaitement satisfaite (9 vs 10), ce qui suggère que l'approximation normale pourrait être légèrement imprécise. Dans ce cas, on pourrait envisager d'utiliser des méthodes plus robustes ou d'augmenter la taille de l'échantillon.